

Resumen ejecutivo

Este trabajo desarrolla un flujo completo de procesamiento SAR desde preprocesamiento y filtrado hasta clasificación temática y creación de un dataset de pares 512×512 para entrenar modelos de despeckle, siguiendo la estructura y alcances evaluativos de la Guía 3 del curso.

Se obtuvieron resultados verificables: mapas de clases, máscaras agua/no-agua, comparativas filtrada vs no filtrada y un dataset ML-ready con metadata formal, demostrando reproducibilidad y trazabilidad exigidas para la sustentación.

Propósito y justificación

El objetivo principal es construir un pipeline reproducible que permita usar imágenes SAR de Sentinel-1 bajo criterios académicos, mitigando speckle, extrayendo clases útiles y generando datos etiquetados para aprendizaje automático, dado que las imágenes SAR son robustas ante nubes y condiciones de iluminación, pero requieren tratamiento especializado.

Esto habilita aplicaciones de monitoreo hidrológico y de cobertura terrestre, mostrando cómo decisiones de filtrado y fusión impactan cuantificaciones como el porcentaje de agua, un indicador relevante para análisis ambientales en el Valle de Aburrá.

Objetivos específicos

- Preparar y filtrar una secuencia de ≥ 5 imágenes SAR, re-escaladas para visualización, sin recorte ni registro en la etapa inicial.
- Aplicar clasificación no supervisada sobre imagen filtrada y sobre la misma sin filtrar, en ≤ 4 clases mapeadas a 0–255, con análisis e interpretación temática.
- Derivar máscaras binarias agua/no-agua desde el clustering previo y cuantificar porcentajes comparando filtrada y no filtrada.
- Registrar y fusionar multitemporalmente las imágenes para construir un ground truth “limpio” y recortar pares 512×512 (noisy/clean) con metadata para entrenamiento.

Datos y alcance

Se trabajó con cinco fechas Sentinel-1 de una misma escena, con re-escalado de intensidad a 0–255 para hacer visibles los contrastes radiométricos previos al filtrado, tal como estipula el reto de imágenes y filtrado.

Las salidas finales incluyen visualizaciones, máscaras, gráficos comparativos y un dataset de parches 512×512 (noisy/ground truth) documentado en JSON con método de registro, imagen base, método de fusión, tamaño de parche y total de ejemplos.

Metodología general

- Re-escalado y filtrado: se re-escalaron todas las escenas a 0–255 y se aplicó filtrado de speckle para mejorar la interpretabilidad sin violar la restricción de no recortar ni registrar en el primer punto.
- Clustering no supervisado: se ejecutó sobre imagen filtrada y sobre la misma sin filtrar, mapeando las clases a 0, 85, 170 y 255 para cumplir el formato 0–255 y facilitar la interpretación por intensidad relativa.
- Agua/no-agua: se tomó la clase de menor intensidad (agua) y se generaron máscaras binarias agua=255, no-agua=0 para ambas imágenes (filtrada y original), con cómputo de porcentajes y comparación.
- Registro y fusión para dataset: se seleccionó una imagen base (noisy), se alinearon el resto a esa referencia y se promedió multitemporalmente para producir el ground truth “limpio”; luego se generaron parches 512×512 emparejados.

Resultados por punto

- Punto 1 (Imágenes y filtrado): se obtuvo una secuencia re-escalada con reducción de speckle y análisis visual por regiones, aportando base estable para la clasificación y comparaciones posteriores exigidas por la guía.
- Punto 2 (Clustering): se generaron mapas de 4 clases en 0–255 para imagen filtrada y no filtrada, habilitando interpretación de coberturas y análisis de diferencias, conforme al diseño evaluativo del reto.
- Punto 3 (Agua/no-agua): se obtuvieron máscaras binarias coherentes con la geografía local y se cuantificaron porcentajes de agua, mostrando por ejemplo 20.732% en la imagen filtrada y 18.093% en la original, con una diferencia absoluta de 2.639%, evidenciado en la visual comparativa y el gráfico de barras.
- Punto 4 (Dataset 512×512): se registraron cinco fechas respecto a una base, se generó el ground truth por promediado y se produjeron pares 512×512 con estructura dataset_patches/noisy y dataset_patches/ground_truth, además de metadata con 5 imágenes usadas, índice de base=3, fusión temporal y tamaño de parche=512.

Evidencias visuales clave

- Imagen base (noisy) y ejemplos registrados muestran alineación espacial suficiente para fusión temporal, requisito previo a la construcción del ground truth.
- Ground truth fusionado refleja reducción del moteado y preserva estructuras, condición útil para entrenar redes de denoising con paridad espacial pixel a pixel.
- Parches emparejados 512×512 demuestran correspondencia entre entradas ruidosas y objetivos limpios, listos para cargas por lotes en entornos de entrenamiento.

Discusión técnica

La diferencia de 2.639% en el porcentaje de agua entre la imagen filtrada y la original muestra que el filtrado previo al clustering tiene un efecto cuantificable sobre la detección de

superficies especularmente reflectivas, como espejos de agua en escenas SAR.image_3.jpg
El promediado multitemporal posterior al registro reduce el speckle y mejora la SNR del objetivo, lo que permite construir pares noisy/clean útiles para aprendizaje supervisado de redes de despeckle, cumpliendo el protocolo académico de creación de dataset.

Conclusiones

El pipeline cumple íntegramente los cuatro retos: preprocesamiento y filtrado, clustering comparativo, extracción agua/no-agua con cuantificación, y fabricación de un dataset de pares 512×512 con documentación formal, listo para entrenar modelos de denoising.

Las evidencias generadas (máscaras, comparativas, gráficos y metadata) permiten sustentar el valor del filtrado y de la fusión temporal para análisis temáticos y para la creación de datos de entrenamiento reproducibles y auditables.

Limitaciones y mejoras

El registro basado en correlación y el promediado uniforme pueden complementarse con estimadores más robustos (mediana o promedios ponderados) y métricas objetivas (SSIM/PSNR) para evaluar calidad de fusión y de parches.

Ampliar el número de parches y experimentar con solapes alternativos puede incrementar la diversidad del dataset, lo que suele traducirse en mejor generalización de modelos de aprendizaje profundo en despeckle SAR.

Reproducibilidad y estructura de entrega

Se mantuvo una estructura por puntos con subcarpetas de insumos, análisis, comparación, validación y métricas, y en el dataset final se documentó el procesamiento en dataset_info.json con método de registro, índice de base, método de fusión, tamaño de parche, total de parches y descripción de carpetas noisy/ground_truth.

Esta documentación facilita la revisión por pares, la repetición de experimentos y la integración directa con frameworks de entrenamiento, cumpliendo las expectativas de evidencia y sustentación de la guía.